Michał Szczygieł	Aleksander Śmierciak	18/06/2014

Zadanie 3 - Trigramy - Analiza dokumentów

Programem spełniającym polecenie zadania 3. jest taki, który przyjmując listę plików wejściowych, przeanalizuje ich zawartość tworząc mapę dystrybucji n-gramów o rozmiarze 3 (trigramów).

Część kodu odpowiedzialna za uzupełnienie informacji o częstości występowania trigramów w tekście źródłowym prezentuje się następująco:

```
1   #pragma omp parallel
2   {
3       unsigned int threadNumber = omp_get_thread_num();
4       unsigned int startPos = chunkSize * threadNumber;
5       unsigned int endPos = chunkSize * (threadNumber + 1);
6       endPos = std::min(endPos, (unsigned int)contents.size());
7       for (unsigned int i = startPos; i < endPos; i += 3)
8       {
9           string trigram = contents.substr(i, 3);
10          ++trigramDistribution[trigram];
11      }
12  }
```

Wcześniejsza implementacja:

```
1   #pragma omp parallel num_threads(threadCount)
2   {
3       std::string threeLetters;
4       unsigned int endPosition = portion * (omp_get_thread_num() + 1);
5
6       if (endPosition > contents.size())
7       {
8           endPosition = contents.size();
9       }
10
11      #pragma for default(none) shared(contents, trigram) firstprivate(
            portion) private(threeLetters)
12      for (int i = portion * omp_get_thread_num();
13            i != portion * (omp_get_thread_num() + 1); i += 3)
14      {
15          threeLetters = std::string(contents.substr(i, 3));
16          trigram[threeLetters]++;
17      }
18  }
```

Była podatna na błędy współbieżnego dostępu do mapy wystąpień trigramów, a także jej wydajność była dużo niższa. Wynikało to zapewne z tego w jaki sposób dane są porcjowane – porcjowanie ręczne pozwala na większą kontrolę nad rozmiarem porcji, co więcej, pozwala ustawić nieregularny rozmiar porcji, co jest szczególnie przydatne, gdy rozmiar danych wejściowych nie jest podzielny przez 3 * [liczba wątków].

Niestety kolekcje standardowej biblioteki szablonów nie są przystosowane do pracy w architekturze wielowątkowej; ich metody nie są pod tym względem bezpieczne. Aby móc bezpiecznie stosować te metody należy zaimplementować własne mechanizm kontroli

dostępów (np. zamki), albo zastosować sekcję krytyczną (*pragma omp critical*).

Przebieg

Obliczenia zostały wykonane na serwerze CUDA.

Poniżej wykresy przedstawiający rezultat przeprowadzonych operacji na wątkach.

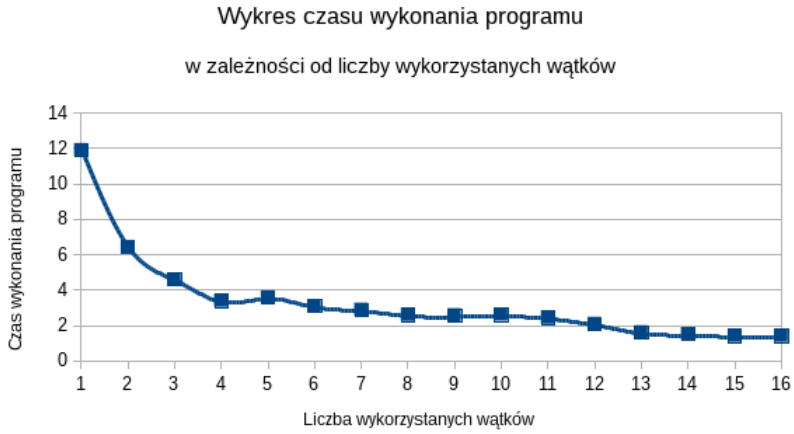

Wykresy z zaimplementowanymi zamkami.

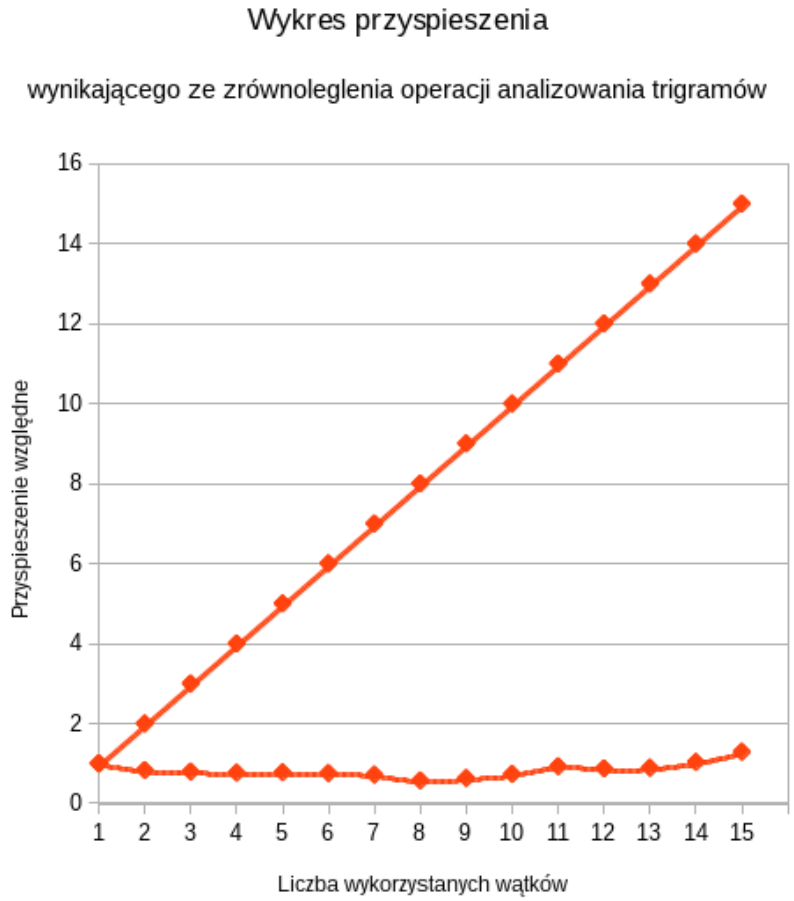

Wnioski

Zauważalny spadek wydajności można tłumaczyć liczbą rdzeni maszyny, na której wykonywano pomiary (serwer CUDA) oraz sposobem przydziału zadań – algorytmem karuzeli – klauzula schedule(static).